

ARTICULO 13

Documento Traducido Automáticamente

Fecha: 03 de September de 2026

Motor: DEEPL

Contenido

Artículo Análisis, predicción y verificación mediante gemelo digital de incendios forestales: un marco «Trinity» y su aplicación Wenyan Li¹, Wenjiao Zai^{1,*}, Wenping Fan¹ y Yao Tang^{2,*} ¹ Facultad de Ingeniería, Universidad Normal de Sichuan, Chengdu 610101, China; 2022180117@stu.sicnu.edu.cn (W.L.); 2022180205@stu.sicnu.edu.cn (W.F.) ² Academia de Ciencia y Tecnología de la Seguridad de Sichuan, Chengdu 610045, China * Correspondence: zaiwenjiao@sicnu.edu.cn (W.Z.); tangyao9528@163.com (Y.T.); Tel.: +86-134-0841-4976 (W.Z.); +86-177-8059-1531 (Y.T.)

Abstract

[ERROR DE TRADUCCIÓN: Rate limit o cuota DeepL excedida: Quota for this billing period has been exceeded, message: Quota exceeded]

In recent years, frequent wildfires have posed significant threats to both the ecological environment and socioeconomic development. Investigating the mechanisms underlying the influencing factors of forest fires and accurately predicting the likelihood of such events are crucial for effective prevention strategies. However, the field currently faces challenges, including the unclear characterization of influencing factors, limited accuracy in forest fire predictions, and the absence of models for mountain fire scenarios. To address these issues, this study proposes a research framework of “decoupling analysis-model prediction-scenario validation” and employs Principal Component Analysis (PCA) and Shapley Additive Explanations (SHAP) value quantification to elucidate the significant roles of meteorological as well as combustible state indicators through multifactor coupling. Furthermore, the Attention-based Long Short-Term Memory (ALSTM) network trained on PCA-decoupled data achieved mean accuracy, recall, and area under the precision-recall curve (PR-AUC) values of 97.82%, 94.61%, and 99.45%, respectively, through 10-time cross-validation, significantly outperforming traditional LSTM neural networks and logistic regression (LR) methods. Based on digital twin technology, a three-dimensional mountain fire scenario evolution model is constructed to validate the accuracy of the ALSTM network's predictions and to quantify the impact of key factors on fire evolution. This approach offers an interpretable solution for predicting forest fires in complex environments.

Academic Editors: Luís Reis and Jorge R.N. Raposo
and provide theoretical and technical support for the digital transformation of forest fire prevention and management. Received: 1 August 2025 Revised: 7 September 2025
Accepted: 4 October 2025

Keywords: influencing factor study; forest fire prediction; digital twin; ALSTM network;
Published: 7 October 2025 PCA; SHAP Citation: Li, W.; Zai, W.; Fan, W.; Tang, Y. Forest Fire Analysis Prediction and Digital Twin Verification: A Trinity Framework and 1. Introduction Application. Forests 2025, 16, 1546.

In recent years, forest fires have become increasingly frequent, establishing themselves as the predominant and most destructive natural disaster within forest ecosystems [1]. Copyright: © 2025 by the authors. Algeria, in particular, has been significantly impacted by this phenomenon. It ranks as the fourth most affected nation according to the European Forest Fire Information System (EFFIS) [2]. This article is an open access article From 2008 to 2017, Algeria experienced over 31,513 forest fires, resulting in the distributed under the terms and conditions of the Creative Commons

burning of more than 320,409 hectares of forested land. The year 2012 alone witnessed over 5110 fires, consuming more than 99,061 hectares [3]. Attribution (CCBY) license (https://creativecommons.org/licenses/by/4.0/). Regions including North America, Australia, and Southern Europe are frequently impacted by large-scale forest fires. In recent Forests 2025, 16, 1546 https://doi.org/10.3390/f16101546

Forests 2025, 16, 1546 2 of 30

years, the wild fire season in the western United States has consistently lengthened, with burned areas repeatedly reaching record levels [4]; During the 2019–2020 fire season in Australia, approximately 18.95 million hectares of forest were destroyed [5]; Similarly, southern European countries such as Portugal and Greece have experienced multiple catastrophic fires, resulting in significant ecological damage and socio-economic consequences [6]. These instances illustrate that forest fires constitute a critical global challenge, necessitating urgent and collaborative responses from the international research community.

To accurately predict the likelihood of forest fires in a given area, it is imperative to identify the factors that contribute to fire occurrence, such as climate, terrain, and fuel conditions [7–9]. Understanding the relationship between these factors and the probability of fire is crucial [10]. These elements, often termed impact factors, significantly impact both the incidence and propagation of forest fires. Meteorological factors are critical determinants [11]. Given this context, the study utilizes a publicly accessible dataset of Algerian forest fires [12] to explore the dynamics of key meteorological factors—such as temperature, humidity, and ambient winds—during forest fire combustion. Additionally,

the study reevaluates the physical significance of extended state indicators, including the Fine Fuel Moisture Code (FFMC), Duff Moisture Code (DMC), and Drought Code (DC). The process of forest fire propagation is complicated by a strong nonlinear coupling of multiple environmental parameters [13–15], which impedes the accurate identification of the individual effects of these factors on fire behavior in empirical studies. The interactions among these factors often lead to feature confusion, thus challenging the ability of models to delineate the independent effects of crucial variables. Principal Component Analysis (PCA), a classical method for reducing dimensionality, offers an effective solution to this

spatial coupling issue [16]. Through PCA, feature extraction is performed, transforming relevant variables into independent principal components (PCs) to minimize information redundancy and achieve feature decoupling while reducing dimensionality. This facilitates the identification of predominant factors in fire risk prediction and provides insights into the impact of each environmental variable on the transitions in forest fire behavior.

Although scholars have attempted to achieve dimensionality reduction and decoupling of high-dimensional variables through PCA, this method primarily addresses the coupling issues of spatial dimensions and does not effectively handle the time-series dependencies of factors such as temperature and humidity, which are crucial for revealing dynamic interactions [17]. To address the temporal coupling issues—namely, the time-lag effects in forest fire data and the dependencies among variables—this study integrates the Attention-based Long Short-Term Memory (ALSTM) network [18]. This approach predicts forest fires using data refined by PCA, aiming to enhance the accuracy of these predictions.

Current research on forest fire prediction predominantly aims to enhance prediction accuracy through the development of advanced algorithms and models. Despite the substantial benefits of machine learning models in addressing nonlinear challenges, their “black box” nature restricts interpretability [19,20], thereby limiting their utility in providing a comprehensive assessment of forest fire prediction outcomes [21]. Consequently, there is a pressing need for an objective and interpretable method to identify the key factors affecting the occurrence of forest fire disasters and to elucidate the decision-making mechanisms of the model.

The Shapley Additive Explanations (SHAP) method [22], one of the most recent interpretable techniques, illustrates the impact of individual features through the collaborative interaction among factors [23]. This method explains each feature’s contribution to

the model output and clarifies the significance and role of each influencing factor in model decision-making. Traditional simulation research on fire occurrence in one-dimensional and two-dimensional forest environments [24–26] is hampered by an inherent limitation: the as-

sumption of low-dimensional space. This assumption fails to capture the dynamic behavior of fire in three-dimensional terrain accurately. Furthermore, the inherent dangers associated with forest fires preclude extensive field testing of predictive analysis techniques. To overcome these limitations, this study adopted digital twin technology to develop a mountain fire scenario evolution model. This model enables the visualization of the impact of meteorological factors on forest fires through 3D scene replication and dynamic parameter adjustment. Furthermore, it allows for the quantification of the evolving dynamics within the traditional Canadian Fire Weather Index (FWI) system metrics and validates the accuracy of predictions made by the ALSTM model. Simultaneously, the model incorporates physically based equations, utilizing the topographical “block” burning equation and forest fire spread speed equation to represent physical spatial processes. This approach provides an additional enhancement and novel application of the forest fire spread model [27]. Based on the foregoing discussion, it can be reasonably concluded that the primary contribution of this paper is the introduction of a tripartite forest fire research framework comprising “decoupling analysis, model prediction, and scenario validation” to address the three principal challenges in forest fire management. This framework integrates three essential stages (e.g., decoupling analysis, model prediction, and scenario validation), each constituting a deeply interconnected cyclical system. Collectively, these stages establish a closed-loop decision support system that extends from data processing to physical perception. The specific rationale underlying this framework is detailed as follows:

1. Decoupling analysis phase: To address the challenge of distinguishing the characteristics of various influencing factors, this study engages in a multi-factor decoupling analysis. By integrating PCA and SHAP, this study develops a framework termed “factors screening-importance ranking-interpretation analysis.” This framework is designed to elucidate the impact of different factors on forest fire occurrence more clearly.
2. Model prediction phase: The research introduces a pioneering approach to spatiotemporal decoupling in model prediction. This involves resolving the issue of spatial coupling of multiple factors through PCA and addressing the time-delay effects using the ALSTM time-series prediction model. By decoupling the spatial and temporal data sources, this method enhances the accuracy of forest fire predictions.
3. Scenario validation phase: Employing digital twin technology, this paper constructs a three-dimensional model that dynamically analyzes the physical mechanisms and quantitative relationships of key meteorological and combustible indices affecting forest fire behavior. This model addresses the limitations of traditional one-dimensional and two-dimensional static simulations and the challenges faced by conventional machine learning models in field testing.

Compared to existing paradigms in forest fire research—including data-driven prediction models [28], physical simulation models [29,30], and hybrid models that integrate data-driven and physical simulation approaches [31–33]—the proposed framework not only achieves high predictive accuracy but also provides interpretability, physical plausibility, and three-dimensional visualization. For a comprehensive comparison and discussion of the distinctions and relationships between this framework and existing paradigms, please refer to Table S1.

2. Related Research

2.1. Research on Influencing Factors

Current academic investigations into the factors affecting forest fires predominantly concentrate on meteorological, topographical, and fuel-related variables and their impact

on the initiation and propagation of fires [34]. Table 1 summarizes various factors that affect the occurrence of forest fires.

Table 1. Classification of forest fire impact factors (grouped by categories, not ranked by importance).
 Derivatives Meteorological Combustibility Topographic Anthropogenic Considerations
 Vegetation Factor Index Factor Factor Factor Factors (FWI System) Normalized Fine Fuel
 Differential Initial Spread Temperature Moisture Slope Ignition Sources Vegetation Index (ISI)
 Code (FFMC) Index (NDVI) Relative Duff Moisture Buildup Slope direction Fire Management
 vegetation type Humidity (RH) Code (DMC) Index (BUI) Impact factor Wind Drought Fire Weather
 Elevation Population Density vegetation cover Speed (WS) Code (DC) Index (FWI) Type
 Topography Distance Rainfall (Rain) vegetative diversity of combustible Complexity
 from the river Distance Atmospheric Pressure Fuel Load terrain roughness vegetation from road
 Research into forest fires has consistently highlighted the role of meteorological conditions in the evolution of these disasters [35, 36]. Numerous studies elucidated the correlations between meteorological elements—such as temperature, humidity, and precipitation—and fire incidence through static correlation analyses. Xiao et al. [37] focused on the Guizhou Qiannan Buyi and Miao Autonomous Prefecture, utilizing the Bayesian estimation model to deduce a correlation between the frequency of forest fires and variations in monthly minimum relative humidity and monthly maximum wind speed. Gao Bo et al. [38] developed a prediction model for forest fires in the Daxinganling region based on logistic regression, assessing and analyzing principal factors affecting fire occurrence. Preisler and Westerling [39] examined the significant impact of meteorological factors and various extended composite indices on the occurrence and progression of fires in the western United States. Despite these advances, the majority of studies have concentrated on static analyses of individual factors, largely overlooking the complex interactions and spatiotemporal variations among different variables. Furthermore, there is a relative paucity of in-depth investigations into the mechanisms through which these factors affect fires. Although there has been an incremental increase in research employing methodologies such as machine learning and statistical modeling [40], the factor studies are evolving to a more dynamic and complex level, but there remains a significant gap in research on state-driven influencing factors under conditions of multi-environmental parameter coupling. Consequently, further research is imperative to unravel the complex relationships between multiple factors across various dimensions.

2.2. Current Status of Forest Fire Prediction
 Forest fire prediction constitutes a critical area of research within the broader context of forest fire prevention and control. In recent years, the robust integration of machine learning technologies has significantly enhanced the precision of predictions in this field [41, 42]. Nevertheless, the spatio-temporal dynamics of forest fires introduce significant time-lag coupling effects among various factors. Current time-series models struggle to effectively capture the dynamic interrelations of these critical factors and often falter due to the interference of redundant information in long-series multivariate data. This results in an imbalance in the allocation of weights and ultimately limits prediction accuracy [43, 44]. To address this challenge, Lin et al. [45] employed the Long-term and Short-term time series network (LSTNet) model to achieve high-precision predictions of forest fires (ACC 0.941), thereby validating the utility of spatial prediction for forest fire

Prevención y control de incendios. En los últimos años, la sólida integración de las tecnologías de aprendizaje automático ha mejorado significativamente la precisión de las predicciones en este campo [41, 42]. No obstante, las dinámicas espaciotemporales de los incendios forestales introducen importantes efectos de acoplamiento con desfase temporal entre diversos factores. Los modelos actuales de series temporales tienen dificultades para captar de forma eficaz las interrelaciones dinámicas de estos factores críticos y, a menudo, fallan debido a la interferencia de información redundante en series largas de datos multivariantes. Esto da lugar a un desequilibrio en la asignación de ponderaciones y, en última instancia, limita la precisión de las predicciones [43, 44]. Para abordar este reto, Lin et al. [45] emplearon el modelo de red de series temporales a largo plazo a corto plazo (LSTNet) para lograr predicciones de alta precisión de incendios forestales (ACC 0,941), validando así

la utilidad de la predicción espacial para los incendios forestales

Forests 2025, 16, 1546 5 de 30 utilizando datos de series temporales. Además, Peng, Le y Cheng et al. [46] desarrollaron la red SimAM Modulated Full Attention Network para abordar los problemas de desequilibrio de datos, mejorando así significativamente la precisión de las predicciones del riesgo de incendios forestales. Basándose en la investigación de otros estudiosos, este estudio incorpora la red ALSTM a la predicción de incendios forestales, optimiza el modelado de la dependencia temporal mediante un mecanismo de gating y se centra dinámicamente en los segmentos temporales ricos en información sobre incendios utilizando pesos de atención. Este enfoque optimiza significativamente el reconocimiento de las contribuciones de los factores clave y mejora la fiabilidad de las predicciones. La opacidad de los modelos de aprendizaje profundo, a menudo denominados sistemas de «caja negra», plantea retos en el uso del aprendizaje automático para la predicción de incendios forestales. Estos modelos suelen permitir únicamente un análisis de la importancia relativa global de cada factor influyente, sin permitir una exploración más profunda de las interacciones entre ellos. El valor SHAP, una técnica de interpretación de modelos basada en la teoría de juegos [22, 47], ofrece una solución sólida a este problema. Abdollah et al. [48] han demostrado que esta técnica puede identificar de forma eficaz los factores clave y esclarecer la lógica de toma de decisiones en la predicción de incendios forestales. Partiendo de investigaciones anteriores, este estudio emplea el análisis del valor SHAP para identificar los factores clave que afectan a la ocurrencia de desastres por incendios forestales y esclarecer el mecanismo de toma de decisiones del modelo. En consecuencia, proporciona a los profesionales de la prevención y el control del riesgo de incendios una comprensión más profunda de los mecanismos de los incendios y fomenta la transición de la predicción de incendios forestales de un paradigma basado en los datos a otro basado en los mecanismos.

2.3. Modelización tridimensional de incendios

Con la evolución iterativa de la tecnología informática, la simulación de incendios se ha convertido en una herramienta fundamental en el ámbito de la prevención y el control de incendios, principalmente a través de la aplicación de la modelización y simulación tridimensional de incendios [49]. La llegada del paradigma de la tecnología del gemelo digital ha introducido ideas y metodologías innovadoras en el ámbito de la simulación de incendios [50]. Zhong et al. [51] presentaron un modelo de incendio de gemelo digital basado en JULES-INFERN0, lo que mejoró significativamente la eficiencia de la predicción en línea dentro del sistema de gemelo digital. Además, Dourvas et al. [52] diseñaron una plataforma de gemelo digital para monitorizar parámetros ambientales como la temperatura y la humedad en el interior de los edificios, mediante la integración de autómatas metacelulares con la tecnología de gemelo digital, logrando así predicciones dinámicas y simulaciones de la propagación del fuego dentro de las estructuras. En el ámbito real de la predicción de incendios forestales, las simulaciones con modelos tridimensionales existentes utilizan principalmente métodos de evolución de puntos en una red espacial basados en reglas, como los autómatas celulares [29]. Aunque estos métodos poseen ciertas capacidades de simulación, por lo general carecen de la integración de los mecanismos físicos esenciales para cuantificar dinámicamente el impacto de factores críticos como la temperatura, la velocidad del viento y la disponibilidad de combustible. Al mismo tiempo, estos sistemas se ven obstaculizados por la presencia de silos de datos, lo que limita su capacidad para dar respuesta de manera eficaz a los requisitos de alerta dinámica de incendios. Además, algunos estudios de simulación se basan en fórmulas de propagación del fuego (p. ej., el modelo USFARSITE 3D [53]) y están evolucionando hacia modelos acoplados multifísicos (p. ej., el modelo WRF-FIRE [54]), así simulaciones inmersivas de incendios forestales impulsadas por IA [55]. Sin embargo, estos enfoques se enfrentan a una disyuntiva entre la eficiencia computacional y el realismo, y a menudo se topan con dificultades a la hora de equilibrar los dos imperativos de velocidad y precisión, esenciales para la prevención y el control de los incendios forestales. La tecnología de gemelos digitales [56–58], caracterizada por su simbiosis con la realidad, su interacción basada en datos y fácil

de usar, y sus funciones de actualización dinámica [59], se ha empleado de forma eficaz empleada para representar con precisión procesos físicos en diversos campos, entre ellos la producción industrial [60], la gestión urbana [61, 62], la asistencia sanitaria [63–65], el sector aeroespacial [66, 67], la gestión de ecosistemas [68, 69], etc. Con este fin, el presente estudio presenta el primer

Forests2025,16,1546 6 de 30 paradigma de validación de incendios forestales basado en gemelos digitales. Integra un motor físico para cuantificar dinámicamente los efectos de factores clave, acoplando profundamente el modelo gemelo con el modelo predictivo, aprovechando datos dinámicos para equilibrar la eficiencia de la simulación y el realismo, confirmando así la viabilidad y la racionalidad de las soluciones de diseño en entornos digitales y virtualizados. Este enfoque supone un avance significativo en la investigación sobre la predicción de incendios forestales. Las relaciones interactivas entre los gemelos digitales forestales se detallan en la Figura S1. 3. Resumen El objetivo de este estudio es investigar la teoría relativa al papel de los factores que influyen en los bosques y mejorar la precisión de la predicción de incendios forestales. Para ello, se desacopla y se reduce la dimensionalidad de las variables medioambientales multidimensionales mediante el análisis de componentes principales (PCA), se extraen los principales factores de influencia, se elimina la información redundante y se realizan predicciones de incendios forestales utilizando la red ALSTM. Este método no solo reduce la dependencia temporal de los datos, sino que también mejora la precisión de la predicción al crear un efecto de desacoplamiento doble espacio-temporal con el PCA. Posteriormente, se emplean los valores SHAP para dilucidar las contribuciones de cada característica al resultado del modelo, aclarando así la importancia de cada factor influyente en la toma de decisiones del modelo y los efectos impulsados por el fuego a través de múltiples gráficos SHAP. Por último, la precisión de los resultados de la ALSTM y el impacto de cada factor influyente en la evolución del incendio se verifican dinámicamente utilizando la técnica del gemelo digital. La estructura general de este estudio se ilustra en la figura 1. Figura 1. Marco de investigación.

Forests 2025, 16, 1546 7 de 30 4. Materiales y métodos 4.1. Preparación de los datos La base de este estudio son los datos sobre incendios forestales, que abarcan variaciones en múltiples dimensiones de datos. El estudio utilizó el conjunto de datos sobre incendios argelinos disponible públicamente [12] (en lo sucesivo, el «conjunto de datos original»). En la versión procesada de este conjunto de datos, las columnas 1 a 10 contienen datos sobre factores que afectan al impacto del incendio, la columna 11 identifica la zona y la columna 12 describe la situación del incendio. Este conjunto de datos incluye factores meteorológicos críticos que influyen en la aparición de incendios forestales, tales como la temperatura, humedad relativa, velocidad del viento y precipitaciones. Además, incorpora seis subíndices principales derivados del sistema del Índice Meteorológico de Incendios de Canadá (FWI), con los siguientes detalles específicos: El sistema del Índice Meteorológico de Incendios de Canadá (FWI) [70, 71] se encuentra entre los índices globales más ampliamente utilizados para evaluar el riesgo de incendios. Este sistema integra mediciones meteorológicas diarias —temperatura, humedad relativa, velocidad del viento y precipitación— teniendo en cuenta los efectos de los tipos de combustible, el contenido de humedad y las condiciones del viento sobre la dinámica del fuego. El sistema FWI consta de seis subíndices principales: tres subíndices básicos que representan la humedad de los combustibles, a saber, FFMFC, DMC y DC; dos subíndices intermedios, que miden la velocidad de propagación y el agotamiento de los combustibles, entre los que se incluyen el ISI y el BUI; y un índice final que cuantifica la intensidad del incendio, denominado FWI. Para el desarrollo del modelo de gemelo digital, se recopilaron datos multidimensionales, entre los que se incluyen registros históricos de incendios, datos topográficos y de vegetación, y condiciones meteorológicas de una sección forestal específica (la entidad física real representada por el modelo de gemelo) en la zona de Bejaia. El modelo digital de elevación ASTER V004, procedente de la de Aeronáutica y del

Espacio (NASA) (Washington, DC, EE. UU.), obtenido a través del sitio web Earth Data de la NASA (<https://www.earthdata.nasa.gov/>, accessed on 16 May 2025), proporcionó parámetros esenciales de pendiente, orientación y altitud para el modelo. Además, los mapas de cobertura del suelo del equipo CCI-LC, que detallan los tipos funcionales de vegetación con una resolución espacial de 300 m (<https://maps.elie.ucl.ac.be/CCI/viewer/index.php>, consultado el 13 de febrero de 2025), sirvieron de base para la modelización de la vegetación del gemelo. Por otra parte, las imágenes satelitales del software Bigemap (Bigemap Pro, versión 1.6.8; <http://www.bigemap.com/>, consultado el 5 de abril de 2025) proporcionaron el contexto ambiental para el desarrollo del modelo.

4.2. Análisis de desacoplamiento multifactorial

4.2.1. Análisis de componentes principales

El PCA se utiliza para evaluar los componentes principales que explican la mayor parte de la varianza en los factores que influyen durante la combustión de los incendios forestales. Esta técnica sirve para reducir la dimensionalidad de los datos [16, 72], extraer elementos latentes críticos y clarificar información compleja. Ayuda a identificar características destacadas dentro de los datos y proporciona un apoyo fundamental para la posterior modelización y análisis. El PCA reconfigura las variables predictoras relevantes en un conjunto reducido de componentes principales (PC) no correlacionados, expresado de la siguiente manera [73]: $X = TP$, (1) donde X es la matriz normalizada de variables predictoras; T representa la matriz de puntuaciones (PC); P denota la matriz de cargas. El PCA reduce eficazmente el número de variables del conjunto de datos al tiempo que conserva la información esencial, como las tendencias dominantes. La determinación del número de PC en este estudio se basó en las tasas de contribución acumulada a la varianza [72]. En aplicaciones prácticas, se suele emplear un umbral empírico del 80 %-90 % para la selección de PC. Dados los estrictos requisitos de integridad y fiabilidad de los datos en los posteriores modelos

Forests 2025, 16, 1546 8 de 30 y en las etapas de optimización de parámetros, se dio prioridad a un umbral de contribución acumulada a la varianza del 90 % para garantizar la retención de la información crítica y mejorar la precisión computacional. Tras el análisis de componentes principales (PCA), la contribución acumulada a la varianza de los cinco primeros componentes principales alcanzó el 91,40 %, lo que indica que estos componentes representaban en conjunto más del 90 % de la varianza presente en el conjunto de datos original. En consecuencia, los cinco primeros componentes principales (PC) se utilizaron como un conjunto de datos secundario (denominado en lo sucesivo «conjunto de datos del PCA»). Estos PC constituían un conjunto de datos comprimido, pero representativo.

4.2.2. Análisis de interpretabilidad

En el ámbito de la inteligencia artificial interpretable, los valores SHAP gozan de un amplio reconocimiento como herramienta fundamental para cuantificar la importancia de las características [74]. Para cualquier muestra específica, el valor SHAP para el parámetro de característica i puede determinarse utilizando la ecuación (2) [75]: $\phi(f, x) = \sum_{z' \subseteq x} \frac{|z'|!(M-|z'|-1)!}{M!} (f(z') - f(z' \setminus i))$, (2) $i \in x$ donde ϕ denota el valor de Shapley de la característica i ; f representa el modelo de caja negra; x denota i el conjunto de características de la muestra; z' indica el subconjunto de características que preceden a la característica i en el conjunto; x' denota el conjunto completo de características; $|z'|!$ calcula las permutaciones del subconjunto i ; $(M-|z'|-1)!$ calcula las permutaciones del subconjunto de características que siguen a la característica i ; $M!$ representa las permutaciones de todas las características; $[f(z') - f(z' \setminus i)]$ mide la diferencia x entre los valores predichos por el modelo con y sin la inclusión de la característica i , cuantificando así el impacto de la característica i en el resultado predicho por el modelo. Este estudio utiliza los valores SHAP para cuantificar la contribución de las características a los resultados de la predicción, empleando la siguiente configuración específica: TreeExplainer (integrado en la biblioteca SHAP, desarrollada por la Universidad de Washington, Seattle, WA, EE. UU.) se utiliza para calcular los valores de Shapley mediante el análisis preciso de las rutas de decisión de los modelos de árbol, lo que permite adaptarse a la arquitectura de conjunto de árboles LightGBM (desarrollada por Microsoft Corporation, Redmond, WA, EE.

UU.) . Las muestras de fondo consisten en el conjunto de datos de entrenamiento completo para representar la distribución temporal de las características, incluidos índices de incendios como el FPMC y el DMC. Se aplica el método de perturbación de características dependiente de la ruta del árbol para captar las dependencias entre características. Las características de entrada se estandarizan mediante la normalización por puntuación Z, lo que da como resultado valores de salida que representan la contribución a las estimaciones de regresión originales. Los gráficos de barras de las variables de características pusieron de relieve los factores determinantes clave del riesgo de incendios forestales, y las características que presentaban valores SHAP más altos se clasificaron como más influyentes, lo que indica un mayor impacto en las predicciones del modelo. Los gráficos de dependencia de las variables de características examinaron las relaciones entre las características y las predicciones, ofreciendo información sobre la relevancia de características específicas en la predicción de resultados. Esta metodología mejora la transparencia del modelo y apoya los esfuerzos en materia de prevención y gestión de incendios forestales. Los datos de entrada para el modelo predictivo de este estudio consisten específicamente en datos de características derivados mediante el desacoplamiento de componentes principales (PCA). El conjunto de datos original incluye factores clave que influyen en los incendios, como el FPMC, el DMC, la temperatura, la humedad, la velocidad del viento y las precipitaciones. Mediante el desacoplamiento mediante PCA, la información contenida en estas variables se transforma en componentes principales (PC) mutuamente independientes. Estos componentes de PCA desacoplados sirven, en última instancia, como entradas para el modelo. Este enfoque no solo reduce la dimensionalidad de las características y elimina la redundancia, sino que también mantiene una correspondencia directa entre las entradas del modelo y los índices de riesgo de incendio establecidos, como el FPMC y el DMC. Como resultado, la interpretación posterior de las contribuciones de las características mediante los valores SHAP puede relacionarse directamente con el conocimiento existente en el ámbito sobre los factores críticos que influyen en los incendios, mejorando así la interpretabilidad específica del modelo en dicho ámbito.

Forests 2025, 16, 1546 9 de 30 4.3. Modelo de predicción de incendios forestales 4.3.1. Diseño de la arquitectura del modelo El proceso de propagación de los incendios forestales se caracteriza por un acoplamiento no lineal y temporal entre diversos factores, como el efecto retardado de los cambios de temperatura en los niveles de humedad. Para abordar esta complejidad, esta investigación emplea una red LSTM mejorada mediante un mecanismo de atención (denominado en lo sucesivo «modelo ALSTM»). El mecanismo de atención perfecciona la capacidad de la LSTM al permitir una concentración selectiva en segmentos de los datos de series temporales de entrada que son más informativos en lo que respecta a la dinámica del fuego [76].

tales 4.3.1. Diseño de la arquitectura del modelo El proceso de propagación de los incendios forestales se caracteriza por un acoplamiento no lineal y temporal entre diversos factores, como el efecto retardado de los cambios de temperatura en los niveles de humedad. Para abordar esta complejidad, esta investigación emplea una red LSTM mejorada mediante un mecanismo de atención (denominado en lo sucesivo «modelo ALSTM»). El mecanismo de atención perfecciona la capacidad de la LSTM al permitir una concentración selectiva en segmentos de los datos de series temporales de entrada que son más informativos en lo que respecta a la dinámica de los incendios [76]. Esta incorporación identifica y amplifica de manera eficaz las características de las series temporales que son fundamentales para la información sobre el incendio, al tiempo que minimiza el impacto de la información irrelevante o redundante. El mecanismo reduce significativamente los problemas relacionados con los gradientes que desaparecen o se disparan, los tiempos de cálculo prolongados y la asignación inadecuada de pesos debida a entradas de secuencias extensas, lo que permite al modelo representar con mayor precisión la compleja estructura lógica y las correlaciones

dinámicas dentro de los datos del incendio, mejorando así el rendimiento de la predicción. La arquitectura correspondiente de codificador-decodificador con el mecanismo de atención se muestra en la figura 2. Figura 2. Arquitectura de codificador-decodificador con un mecanismo de atención. El módulo de atención dentro de esta arquitectura aprende de forma autónoma los pesos de atención, α , y captura los estados h (donde h , denominado «estado candidato», representa el i del codificador, y s , denominado «estado de consulta», representa el estado oculto del j decodificador, existiendo una correlación discernible entre ambos). Posteriormente, el mecanismo de atención construye el vector de contenido c , asignando pesos de atención más precisos. Estos ponderes facilitan una transición más lógica entre s durante la decodificación y h durante i la codificación. El vector de contenido c representa la suma ponderada de todos los estados ocultos del j codificador, multiplicada por sus respectivos ponderes de atención, tal y como se muestra en la ecuación (3) [77,78]:
$$T \sum_{i=1}^j c = \alpha$$

Forests2025,16,1546 10 de 30 El funcionamiento del mecanismo de atención es similar al de una red neuronal de avance, aunque con un aprendizaje específico de los pesos de atención especiales α , que son esenciales para i construir la función de conversión entre h y s $j-1$ durante el proceso de aprendizaje. La red ALSTM desarrollada en este estudio incorpora un mecanismo de activación potencial, detallado en la Tabla 2. Tabla 2. Explicación de la red ALSTM. Forma de salida Nombre de la capa Tipología Parámetros/Configuración Función

Extrapolación Recibe datos de series temporales preprocesados input_layer capa de entrada - (None, 1, 7) tras la reducción de dimensionalidad mediante PCA Captura dependencias secuenciales Unidades = 64, LSTM Capa LSTM return_sequences=True, (Ninguno, 1, 64) extrae características temporales Activación=tanh mediante mecanismos de activación Unidades=1, calcula la atención bruta Dense_1 capa de conectividad total (Ninguno, 1, 1) Activación=tanh normaliza las puntuaciones de los pesos Normaliza la atención Activación: capa de activación Activación = softmax (None, 1, 1) que transforma los pesos en una distribución de probabilidad Aplica la atención elemento por elemento Multiplica - (None, 1, 64) los pesos por las salidas de la LSTM, mediante multiplicación para enfatizar las características clave Reduce la dimensión temporal global mediante GlobalAveragePooling1D - (Ninguno, 64) agrupación por promedios, conservando la información de las características Realiza una transformación no lineal Unidades = 64, y capa de conectividad total Dense_2 (Ninguno, 64) Activación = ReLU: mapeo avanzado de características Desactiva aleatoriamente Dropout: inactivación estocástica Tasa = 0,3 (Ninguno, 64) el 30 % de las neuronas para evitar el sobreajuste Genera una Unidades=1, Dense_3 capa de entrada (Ninguna, 1) probabilidad de clasificación Activación=sigmoide para la ocurrencia de incendios El enfoque propuesto se optimizó específicamente para la predicción de incendios forestales mediante un modelo de series temporales: (1) Extracción de características de series temporales: Este estudio emplea una capa LSTM para captar las dependencias a largo plazo dentro de los datos de la secuencia. Los mecanismos de control de la capa —que comprenden una puerta de olvido, una puerta de entrada y una puerta de salida— modelan de forma eficaz la dinámica temporal asociada a los factores relacionados con los incendios. (2) Fusión de atención: se introduce una capa «Multiply» para lograr una fusión ponderada entre los pesos de atención y los estados ocultos de la LSTM, haciendo así hincapié en los factores clave que impulsan los incendios forestales. (3) Eficiencia y generalización: Para reducir la dimensionalidad y, en consecuencia, el número de parámetros y la sobrecarga computacional, este estudio utiliza una capa de Global Average Pooling 1D. Además, se incorpora una capa de «dropout» con una tasa de inactivación del 0,3

Forests 2025, 16, 1546 11 de 30 se incorpora para mitigar eficazmente el riesgo de sobreajuste, mejorando así la capacidad del modelo para generalizar en entornos forestales diversos y variables. (4) Salida probabilística: El modelo concluye con una capa que utiliza una función de activación sigmoide, la cual genera la probabilidad de que se produzca un

incendio forestal dentro de un intervalo de $[0,1]$. Para desarrollar un modelo predictivo de incendios forestales, la investigación utilizó datos de PC, entrenando el ALSTM con pasos temporales cada vez mayores. Este modelo se utilizó finalmente para estimar la probabilidad de que se produzcan incendios forestales.

4.3.2. Experimentos de optimización de parámetros clave

1. Optimización del intervalo de tiempo

El intervalo de tiempo es un parámetro crucial que afecta a la capacidad del modelo ALSTM para captar las dependencias temporales. Para investigar su impacto, este estudio llevó a cabo experimentos en los que se comparó el rendimiento de distintos tamaños de paso (1, 2, 5, 10) a lo largo de 100 iteraciones (Figura 3). (a) (b) (c) (d) (e) (f) Figura 3. Curvas de pérdida y precisión en el entrenamiento para diferentes tamaños de paso. (a) Curva de descenso de la pérdida en el conjunto de entrenamiento; (b) fluctuación de la pérdida en el conjunto de validación; (c) mejora de la precisión en el conjunto de entrenamiento; (d) Métricas de precisión en el conjunto de validación; (e) Mejora de la precisión en el conjunto de entrenamiento; (f) Rendimiento de la precisión en el conjunto de validación.

Forests 2025, 16, 1546 12 de 30 Las comparaciones experimentales de los tamaños de paso temporal indican que un tamaño de paso de 2 ofrece un rendimiento óptimo del modelo. La pérdida de entrenamiento se reduce drásticamente hasta aproximadamente 0,05, y la pérdida de validación hasta aproximadamente 0,07, lo cual es sustancialmente superior a las pérdidas observadas con otros tamaños de paso. Al mismo tiempo, tanto la exactitud como la precisión del entrenamiento y la validación aumentan rápidamente hasta alcanzar niveles elevados con una fluctuación mínima. Estos resultados sugieren que un paso de 2 proporciona una representación estable y fiable de las características temporales para la vigilancia de incendios forestales. Por lo tanto, se selecciona un paso de 2 como parámetro óptimo de ventana temporal para el modelo ALSTM.

2. Optimización de la tasa de aprendizaje

La tasa de aprendizaje es un parámetro fundamental que determina la magnitud de las actualizaciones realizadas en los parámetros del modelo, lo que afecta directamente a la velocidad de convergencia y al rendimiento general del modelo. Para determinar la tasa de aprendizaje óptima, en este artículo se supervisó la pérdida de entrenamiento con diversas tasas de aprendizaje, manteniendo un tamaño de paso fijo de 2 (Figura 4). Figura 4. Pérdidas con diversas tasas de aprendizaje. El análisis reveló que una tasa de aprendizaje de 0,0178 permite la convergencia más rápida y una tendencia de descenso de la pérdida suave, con los valores de pérdida más bajos y más estables. Esto indica que esta tasa de aprendizaje equilibra de forma óptima la aceleración de la convergencia con el mantenimiento de la estabilidad. Por lo tanto, se ha elegido esta tasa de aprendizaje, 0,0178, como parámetro de entrenamiento para el modelo ALSTM.

3. Selección del optimizador

La selección de un optimizador es fundamental, especialmente en tareas que requieren precisión, como la predicción de incendios forestales. En este estudio, se evaluaron cinco optimizadores —Adam, SGD, RMSprop, Adagrad y Nadam— se evaluaron utilizando el mismo conjunto de datos de reducción de dimensionalidad de PCA (Figura 5 y Tabla 3). Los resultados de la evaluación demuestran que todos los optimizadores probados alcanzan precisiones superiores al 96,00 % en el conjunto de prueba. Sin embargo, se observan variaciones significativas en sus métricas de precisión y recuperación. Dada la necesidad crucial de una baja tasa de falsos positivos (alta precisión) en la predicción de incendios forestales, el optimizador Adam demuestra ser superior al mantener una excepcional precisión de 0,9983 y un recall de 0,9361, junto con la mayor precisión global (96,72 %). Por lo tanto, se ha seleccionado el optimizador Adam para el modelo ALSTM.

Forests 2025, 16, 1546 13 de 30 En resumen, la configuración final de los parámetros para el modelo ALSTM incluye un tamaño de paso de 2, una tasa de aprendizaje de 0,0178, una tasa de dropout de 0,3 y el optimizador Adam. Esta configuración garantiza que el modelo logre un equilibrio entre alta eficiencia, estabilidad y precisión en la tarea de predecir incendios forestales. (a) (b) (c) (d) Figura 5. Comparación de los resultados de entrenamiento

de cinco optimizadores. (a) Precisión de entrenamiento y validación; (b) Pérdida de entrenamiento y validación; (c) Comparación de métricas del conjunto de prueba; (d) Comparación de la pérdida de validación. Tabla 3. Comparación de la robustez de los optimizadores. Optimizador Precisión Exactitud Recuperación Adam 96,72 % 0,9983 0,9691 SGD 96,10 % 0,9167 0,9856 RMSprop 96,56 % 0,9248 0,9741 Adagrad 96,45 % 0,9156 0,9826 Nadam 96,06 % 0,9211 0,9778

4.4. Modelo de evolución de incendios forestales en montaña Este estudio detalla la construcción de un modelo de evolución de incendios forestales en montaña, que abarca tres componentes fundamentales: la formulación de ecuaciones físicas determinantes, la integración de datos dinámicos y el desarrollo de un modelo tridimensional. Las ecuaciones dinámicas sirven de base mecánica para simular la propagación virtual del fuego, garantizando que la evolución del incendio se ajuste a las leyes físicas. Además, las modificaciones de los escenarios del modelo impulsadas por el Internet de las Cosas (IoT) facilitaron la simulación dinámica de la propagación de los incendios forestales. Mediante el software Digital Twin Designer, el modelo integra datos de múltiples fuentes para crear una representación digital visual coherente que simula de forma eficaz el avance de un incendio forestal. A través de esta integración fluida de estos tres componentes, el gemelo digital

Forests 2025, 16, 1546

14 de 30

marco de trabajo hace avanzar la simulación tradicional de escenarios estáticos hacia una validación predictiva dinámica . El modelo gemelo resultante funciona no solo como una representación digital visualizada del proceso de combustión de un incendio forestal, sino también como una herramienta de verificación que conecta las predicciones del ALSTM con los escenarios reales de propagación del fuego.

4.4.1. Ecuaciones físicas determinantes El modelo tridimensional analizado en este estudio integra factores meteorológicos, combustibles y topografía para simular el proceso de combustión. Establece modelos cinéticos independientes para los parámetros ambientales basados en datos históricos, la ecuación de combustión topográfica «» y la ecuación de la velocidad de propagación del incendio forestal dentro de un marco de gemelo digital . Este enfoque respalda los procesos físico-espaciales explorados en este estudio. La ecuación topográfica de combustión «en bloque» se utiliza para determinar la presencia o ausencia de llamas. Se identifican tres mecanismos principales de ignición en el suelo [79]: (1) propagación por el suelo, (2) dispersión aérea de chispas y (3) una combinación de ambas: propagación por el suelo y dispersión aérea. Para que se produzca una ignición por el suelo, deben cumplirse las siguientes condiciones: $v \cdot n \cdot I \rightarrow J \geq 0$, (4) donde v denota la velocidad del viento ambiental (m/s), que representa la velocidad a la que el flujo atmosférico circundante influye en el movimiento de las partículas; $n \cdot I \rightarrow J$ representa la transición de la celda i a la celda j . Cuando se cumplen estas condiciones, las llamas pueden propagarse a las celdas adyacentes mediante propagación por el suelo. La ecuación de combustión para la masa de la unidad de bloque de suelo es la siguiente: $\dot{M} = \beta \zeta$, (5) I donde β indica la velocidad de combustión, determinada por el estado del material combustible I , y ζ representa una función de corte «evolutiva», que varía de 0 a 1 I (hasta que se agota la masa en combustión, según lo determinado por la masa inicial). Para la ignición de partículas de combustión en suspensión, deben cumplirse las siguientes condiciones tanto para la partícula de combustión i como para la celda J : $\{(cid:12) \mid (cid:12) \mid \{ (cid:12)x \mid i(t) - x \mid J(cid:12) \leq J \mid (cid:12) \mid (cid:12) \mid (cid:12)y \mid i(t) - y \mid J(cid:12) \leq J \mid \text{tol} \}$, (6) $\mid \mid z(t) \leq z \mid J \mid J \propto \alpha M \cdot$, (7) $\text{tol} \mid J$ donde $x(t)$, $y(t)$ y $z(t)$ denotan las coordenadas de la i -ésima partícula de combustión en los ejes x , i y y y z a lo largo del tiempo, respectivamente, dentro del espacio del modelo. x , y y z denotan las J J J posiciones límite de la celda J -ésima en los ejes x , y y z , respectivamente, en el espacio del modelo. J denota una variable proporcional a la masa de la masa base de la celda J -ésima de $\text{tol} \cdot$ la unidad de bloque; α es el coeficiente de escala, y M denota la tasa de variación de la masa en la J masa de base de la celda J -ésima de la unidad de bloque. Los factores meteorológicos, como elementos dinámicos, ejercen un impacto considerable en los incendios forestales, especialmente cuando el viento sopla en la misma dirección que la

propagación de las llamas, lo que acelera directamente la velocidad de propagación del incendio forestal [80]. Por consiguiente, es imprescindible tener en cuenta los principales factores que influyen, como el tipo de combustible, la velocidad del viento, la humedad y la pendiente, en la formulación de la ecuación de la velocidad de propagación de los incendios forestales, tal y como se indica a continuación [81]: $R = R \times K \times K \times K \times K$ (8) $0 \phi \theta S r$

Forests2025, 16, 1546 15 de 30 $R = a \times T + b \times W + c \times (100 - RH) - d$, (9) (cid:16) v (cid:17)² $W = \text{Int } 3$, (10) $0,836 K = e^{1,1 \times 10^{-3} \times v \times \cos \phi}$, (11) $\phi K = e^{3,1 \times 10^{-3} \times g \times \tan(1,2 \times \theta)}$. (12) θ En las ecuaciones mencionadas anteriormente, R representa la velocidad de propagación del incendio forestal (m/min), R denota la velocidad inicial de propagación del incendio forestal (m/min), K es el coeficiente de corrección del viento, $0 \phi K$ es el coeficiente de corrección del terreno, K indica el índice de inflamabilidad [82], y K es $\theta S r$ el coeficiente de corrección temporal (ajustado según las condiciones reales del incendio). Las constantes se definen como $a = 0,03$, $b = 0,05$, $c = 0,01$ y $d = 0,3$. Además, T representa la temperatura del aire (°C), W indica la velocidad del viento (m/s), RH es la humedad relativa del aire, I es un marcador de posición entero (%), v denota la velocidad del viento (m/s) y $\cos \phi$ es el coseno del ángulo de dispersión entre la dirección del viento y la dirección del incendio. La variable θ representa la pendiente, y g indica la dirección de la pendiente, donde 1 representa cuesta arriba y -1 cuesta abajo. Además, el contenido de humedad de los combustibles influye en la velocidad inicial de propagación de los incendios forestales, lo que requiere un ajuste tal y como se describe en la ecuación (13) [83], donde m es el contenido de humedad de los combustibles (%): $R = 1,0372 \times e^{(-0,057 \times m)}$. (13) 0 Las ecuaciones (8)-(13) permiten cuantificar los efectos dinámicos de la velocidad del viento, el gradiente de la pendiente y el contenido de humedad del combustible (FFMC, DMC y DC) sobre las trayectorias y velocidades de propagación del fuego. Este enfoque facilita la reconstrucción de los mecanismos subyacentes que rigen los comportamientos reales del fuego, incluida la aceleración del fuego cuesta arriba y la extensión del fuego a favor del viento. 4.4.2. Preparación de datos para la construcción del modelo gemelo La construcción del escenario de simulación requiere la integración de datos de múltiples fuentes y la capacidad de control dinámico. Este estudio importa datos relevantes, tales como datos meteorológicos, de combustibles, del terreno y del campo de incendio, al Fulima Cloud J3D Digital Twin Designer (<https://www.fulima.com/>, accessed on 2 November 2024).

te enfoque facilita la reconstrucción de los mecanismos subyacentes que rigen los comportamientos reales del fuego, incluida la aceleración del fuego cuesta arriba y la extensión del fuego a favor del viento. 4.4.2. Preparación de datos para la construcción del modelo gemelo La construcción del escenario de simulación requiere la integración de datos de múltiples fuentes y la capacidad de control dinámico. Este estudio importa datos relevantes, como los meteorológicos, los de combustibles, los del terreno y los del campo de incendio, al Fulima Cloud J3D Digital Twin Designer (<https://www.fulima.com/>, accessed on 2 November 2024). Mediante la integración de datos con interfaz de tipo MQTT, se establece un mecanismo de control dinámico basado en el IoT para facilitar la correspondencia entre las escenas virtuales y los entornos forestales reales. La construcción del modelo digital del entorno de incendios forestales abarca la simulación precisa de múltiples elementos. Mediante el uso del FulimaCloud J3D Digital Twin Designer, se genera una escena completa que incluye estructuras básicas de modelos de montañas, suelos y árboles, basadas en datos meteorológicos históricos importados, datos de topografía forestal y geomorfología, así como datos de distribución de la vegetación. A continuación, se emplean técnicas de alineación espacial para posicionar con precisión cada modelo localizado, formando así una escena forestal coherente. Se asignan parámetros físicos a cada elemento de la escena, y sus valores se actualizan continuamente mediante ecuaciones de transición de estado y flujos de datos del IoT, lo que proporciona un apoyo paramétrico esencial para las simulaciones de combustión posteriores. El proceso de

modelización del entorno del incendio forestal se ilustra en la figura 6. El proceso de combustión de un incendio forestal descrito en este estudio se caracteriza por tres estados principales: el estado «sin quemar», el estado «llama abierta» y el estado «extinguido». Las transiciones dinámicas entre estos estados, junto con sus simulaciones visuales, se facilitan mediante un código de eventos de devolución de llamada de la interfaz que integra las ecuaciones físicas que rigen el proceso. La lógica específica que rige estas transiciones se resume en la Tabla 4.

Forests2025,16,1546 16 de 30 Figura 6. Proceso de construcción del entorno virtual del gemelo digital.

Forests2025,16,1546 17 de 30 Tabla 4. Tabla de lógica de transición de estados. Estado de la situación Condición desencadenante Eventos de interacción y efectos en la escena La vegetación conserva sus texturas y Los parámetros ambientales no cumplen las condiciones de combustión y la topografía no permite la combustión, lo que da lugar a que no haya efecto de humo en la escena; el «bloque» impide la combustión, y se muestra un modelo tridimensional como un entorno natural estático. Se activa el sistema de partículas de llama y el modelo de llama se expande a medida que los parámetros ambientales cumplen las condiciones de combustión, la temperatura aumenta y se generan partículas de humo; no estado de llama abierta se genera simultáneamente; la vegetación y el «bloque» topográfico impiden que el modelo pase dinámicamente a una textura de combustión, realizada por efectos de partículas como chispas y salpicaduras. Las partículas de llama se desintegran gradualmente y desaparecen, los parámetros ambientales ya no y la concentración de humo disminuye; el cumplen las condiciones de combustión o el modelo de vegetación se actualiza a un estado «quemado» estado «extinguido» El «bloque» topográfico impide la textura, conservando indicios de un posible reavivamiento de la combustión si queda material combustible sin quemar.

5. Resultados y análisis 5.1. Resultados de los análisis de desacoplamiento 5.1.1. Resultados del análisis de componentes principales El PCA desentrañó eficazmente las complejas interacciones entre los factores que afectan a los incendios forestales, revelando las dimensiones fundamentales que rigen la probabilidad de que se produzcan incendios en la zona de estudio argelina (Figura 7 y Tabla 5). Tras aplicar el PCA al conjunto de datos completo, las cinco primeras componentes principales (PC) explicaron de forma acumulativa el 91,40 % de la varianza total, lo que demuestra que el complejo conjunto de datos se condensó en varios ejes principales de variación. En concreto, la PC1, con altas cargas de índices como el ISI y el FPMC, capta la dimensión principal de «sequedad de los combustibles y potencial de incendio». El PC2 articula la dimensión crítica de «efecto de la velocidad del viento y grado de sequía», que contribuye de manera significativa a la rápida propagación y al aumento de la intensidad de los incendios. El PC3, el «efecto de supresión de la humedad», cuantifica cómo las condiciones de humedad inhiben la inflamabilidad y el mantenimiento de las llamas en los materiales combustibles. Los PC 4 y 5 recogen la dimensión de la «interacción local entre el viento y la temperatura y la heterogeneidad espacial», reflejando los efectos secundarios, aunque dignos de mención, de los patrones específicos de cada región en cuanto a velocidad del viento, temperatura y variabilidad espacial sobre la ocurrencia de incendios. Entre las representaciones gráficas más informativas de conjuntos de datos multivariantes se encuentran los diagramas biplots [84]. Estos gráficos facilitaron la distinción entre los casos de «incendio» y «sin incendio» en la figura 8, donde un patrón claro de separación reafirma que el PCA desentraña eficazmente los factores contribuyentes y aclara las principales dimensiones impulsoras. Las cargas de las variables características, tal y como indican las flechas de la figura 8, muestran que ISI, FPMC, FWI, DMC, y BUI se agrupan estrechamente en la dirección positiva del PC1, lo que subraya su papel cohesionador a la hora de caracterizar la dimensión de «sequedad combustible y potencial de incendio». Por el contrario, la humedad relativa (RH) y las precipitaciones se agrupan en la dirección negativa del PC1, lo que pone de relieve su

impacto colectivo en la dimensión de la «supresión de la humedad». Ws y DC se orientan hacia el PC2, lo que demuestra sus mecanismos de acción distintivos, independientes del PC1. La temperatura aparece tanto en el PC1 como en el PC2, lo que sugiere su doble impacto: aumenta indirectamente el riesgo al acelerar el proceso de secado y constituye una dimensión independiente debido a sus patrones variables.

Forests 2025, 16, 1546 18 de 30 Figura 7. Gráfico de varianza explicada del ACP. Tabla 5. Tabla resumen del ACP. Explicación de la varianza acumulada Componentes principales Impactos medioambientales Varianza (%) Varianza (%) PCA1 52,61 52,61 FWI, FPMC, DMC, ISI, BUI PCA2 15,93 68,54 Ws, DC PCA3 9,47 78,01 Lluvia, HR PCA4 7,35 85,36 Ws, Temperatura PCA5 6,04 91,40 Región

Figura 8. Bi-plots de las variables características del PCA y la distribución de la muestra. En conclusión, el PCA no solo logra una reducción de la dimensionalidad de los datos, sino que, lo que es más importante, descompone el sistema de interacción multifactorial. Identifica las dimensiones principales de «sequedad del combustible y potencial de incendio» (PC1) y «efecto de la velocidad del viento y grado de sequía» (PC2), junto con el «efecto de supresión de la humedad» (PC3) y dos dimensiones secundarias. Este enfoque analítico proporciona un marco coherente para comprender los mecanismos predominantes que impulsan la aparición de incendios forestales en Argelia y establece una base sólida para la introducción de características y la interpretabilidad en los posteriores análisis de modelos predictivos.

Forests 2025, 16, 1546 19 de 30 5.1.2. Análisis de las contribuciones de las variables Se llevó a cabo un análisis de valores SHAP en el modelo ALSTM, que se entrenó utilizando tanto las características originales como las reducidas mediante PCA, con el fin de examinar los factores principales que afectan a la predicción de incendios forestales y sus mecanismos operativos. Este análisis también tenía como objetivo evaluar cuantitativamente si los datos reducidos mediante el PCA conservaban la información esencial pertinente para la predicción de incendios que se encontraba en los datos originales, validando así la eficacia de la desacoplamiento espacial. La relevancia de los 11 factores determinantes se determinó mediante una agregación de los valores SHAP de todas las variables características de la figura 6. En las figuras 9a y 9b, la importancia del ISI y el FPMC supera significativamente a la de las demás variables. Esta observación subraya el papel crucial que desempeñan la velocidad de dispersión de los combustibles y el estado de humedad de los combustibles finos a la hora de influir en los resultados del modelo. A estos factores les siguen en importancia el FWI y la RH, lo que concuerda estrechamente con los temas centrales de «sequedad de los combustibles y potencial de incendio» (representados predominantemente por el PC1) y «supresión por humedad» (dominado por el PC3), tal y como los identifica el PCA. El impacto de variables como WS y DC parece menos pronunciado, aunque sigue siendo digno de mención, en consonancia con su asociación con la dimensión del «efecto de la velocidad del viento y el grado de sequía» (PC2). En el conjunto de datos del PCA, el PC1 resume la mayor parte de la información fundamental para la predicción de incendios en el conjunto de datos original, lo que confirma que factores clave como el ISI y el FPMC son predominantes en el análisis de características original. (a) (b) (c) (d) Figura 9. Resultados gráficos de la variable de características SHAP. (a) Gráfico de barras para el conjunto de datos original; (b) gráfico de barras para el conjunto de datos de PCA; (c) gráfico de dependencia para el conjunto de datos original; (d) gráfico de dependencia para el conjunto de datos de PCA. En la figura 9c, los impactos positivos significativos de ISI y FFM en los resultados del modelo se ilustran las flechas rojas, reflejando sus características intrínsecas: mientras que el ISI denota una velocidad de propagación más rápida y un mayor potencial de combustión, el FFM indica una alta propensión a la combustión debido a las condiciones de sequedad. El efecto de otros factores es comparativamente débil, lo que

Forests 2025, 16, 1546 20 de 30 puede verse eclipsado por los efectos dominantes de FFMCI y ISI, lo que dificulta una elucidación clara de sus mecanismos. En la figura 9d, el PC1 muestra un efecto positivo fuerte y monótonamente creciente, en consonancia con los efectos de ISI y FFMCI, lo que sugiere que el análisis de componentes principales (PCA) concentra y amplifica eficazmente las señales fundamentales relacionadas con el riesgo de incendio, al tiempo que elimina el ruido extraño. El análisis integrado que utiliza tanto el PCA como el SHAP no solo cuantifica la clasificación por importancia de los factores de impacto: $ISI \approx FFMCI > FWI > RH > Temperatura > Lluvia > DMC > BUI > WS > DC$, sino que, lo que es más importante, aclara la jerarquía fundamental de los mecanismos que provocan los incendios forestales en Argelia. Los resultados indican que la sequedad de los materiales combustibles es el factor predominante para el inicio de un incendio a cielo abierto, constituyendo el requisito previo fundamental para que se produzca el incendio. El potencial de propagación del fuego, representado por el ISI, y las condiciones meteorológicas inmediatas, afectadas por el WS, determinan la velocidad de desarrollo de un incendio una vez iniciado. La alta humedad se perfila como el supresor natural más eficaz de los incendios, mientras que la temperatura indica principalmente si se iniciará un incendio en un lugar determinado.

5.2. Resultados de predicción del modelo

Para validar el rendimiento predictivo del modelo ALSTM propuesto dentro del marco de «desacoplamiento espaciotemporal doble», este estudio llevó a cabo análisis comparativos del rendimiento del entrenamiento y evaluaciones de precisión multimétricas.

5.2.1. Mejora del efecto del entrenamiento mediante el desacoplamiento de características

Durante la fase de entrenamiento, este estudio evaluó el rendimiento de un modelo ALSTM entrenado con el conjunto de datos completo original de características frente al que utilizaba datos reducidos en dimensionalidad mediante PCA. La función de pérdida y las curvas de predicción de probabilidad se representan en la figura 10.

(a) (b) Figura 10. Función de pérdida y curva de predicción. (a) Curva de entrenamiento con datos de características completos sin procesar; (b) curva de entrenamiento tras la reducción de dimensionalidad mediante PCA. El análisis de los resultados revela que la curva de pérdida del conjunto de datos original (Figura 10a) disminuye gradualmente y presenta fluctuaciones en las últimas iteraciones, lo que sugiere que la redundancia de características dificulta la eficiencia de convergencia del modelo y limita su capacidad de generalización. Por el contrario, la curva de pérdida del conjunto de datos reducido mediante PCA (Figura 10b) muestra un rápido descenso hasta 0,05 en 10 iteraciones y se mantiene estable a partir de ahí, lo que confirma una pérdida consistentemente menor en comparación con el conjunto de datos original. Esta evidencia respalda de forma sólida la afirmación de que la reducción de la dimensionalidad mediante el PCA no solo simplifica el espacio de características al eliminar la redundancia y el ruido, sino que también mejora la convergencia del modelo, la estabilidad de las predicciones y el rendimiento de generalización. Para corroborar aún más las ventajas de rendimiento de ALSTM en la predicción de incendios forestales, se seleccionaron modelos tradicionales LSTM y LR para la comparación. Se llevaron a cabo diez experimentos independientes utilizando el mismo conjunto de datos de PCA para evaluar el rendimiento de ALSTM en relación con los modelos tradicionales LSTM y LR. En cada experimento, los conjuntos de entrenamiento y prueba

Forests 2025, 16, 1546 21 de 30 se volvieron a dividir aleatoriamente utilizando diferentes semillas aleatorias. Los resultados de la comparación se resumen en la Tabla 6.

Modelo	Precisión	Exactitud	Recuperación	F1	PR-AUC
ALSTM	0,9782 ($\pm 0,0237$)	0,9571 ($\pm 0,0213$)	0,9461 ($\pm 0,0373$)	0,9612 ($\pm 0,0196$)	0,9945 ($\pm 0,0048$)
LSTM	0,9634 ($\pm 0,0434$)	0,9449 ($\pm 0,0205$)	0,9398 ($\pm 0,0402$)	0,9499 ($\pm 0,0164$)	0,9926 ($\pm 0,0068$)
LR	0,9865 ($\pm 0,0208$)	0,9224 ($\pm 0,0238$)	0,8710 ($\pm 0,0396$)	0,9246 ($\pm 0,0243$)	0,9893 ($\pm 0,0087$)

La comparación de los parámetros clave indica que ALSTM supera a los demás modelos en la mayoría de los indicadores, demostrando especialmente un rendimiento excepcional en la recuperación y la puntuación F1, lo que subraya su eficacia general superior. Para garantizar la solidez y la potencia estadística, la

investigación llevó a cabo pruebas t pareadas para comparar el rendimiento de los modelos. Para cada experimento, se realizaron pruebas t de una sola muestra sobre las diferencias en las métricas de rendimiento entre ALSTM y los modelos de comparación (LSTM, LR), con la hipótesis nula de que «la diferencia de las métricas es cero». Los resultados revelan no solo la media $\pm$ desviación estándar de las métricas originales, sino también la diferencia media, el intervalo de confianza del 95 % y el valor p para evaluar la significatividad estadística. Este análisis exhaustivo confirma si la superioridad de ALSTM sobre los modelos de referencia es estadísticamente significativa (Tabla 7).

Tabla 7. Análisis de significación estadística de la comparación del rendimiento de los modelos (basado en pruebas t pareadas de 10 experimentos independientes).

Métrica	Comparación	Diferencia media	Límite inferior del IC del 95 %	Límite superior del IC del 95 %	Valor p
Precisión	ALSTM frente a LSTM	0,012244898	0,001859192	0,026348988	0,001126189*
Precisión	ALSTM frente a LR	0,034693878	0,017766171	0,051621584	0,001225564*
Precisión	ALSTM frente a LSTM	0,014776261	0,009789991	0,039342513	0,002718957*
Precisión	ALSTM frente a LR	-0,008263151	0,006996895	0,010470593	0,004445289*
Recuperación	ALSTM frente a LSTM	0,006283075	-0,011413825	0,023979976	0,442580109
Recuperación	ALSTM frente a LR	0,07508576	0,045020052	0,105151469	0,000313807*
Puntuación F1	ALSTM frente a LSTM	0,011346472	0,00163506	0,024328005	0,00941261*
Puntuación F1	ALSTM frente a LR	0,036625092	0,01861564	0,054634543	0,001289685*
PR-AUC	ALSTM frente a LSTM	0,001909956	0,000994991	0,004814904	0,001099468*
PR-AUC	ALSTM frente a LR	0,005237726	0,000113348	0,010362104	0,046070699*

*Indica significación estadística con un nivel de $\alpha = 0,05$. En comparación con el modelo LSTM (Tabla 7), el modelo ALSTM muestra mejoras estadísticamente significativas en la imprecisión, la precisión, el índice F1 y el área bajo la curva de precisión-recuerdo (PR-AUC). Además, en comparación con el LR, el ALSTM muestra mejoras significativas en la inexactitud, el recall, el índice F1 y el PR-AUC. Estos resultados confirman el rendimiento superior del modelo ALSTM con respecto tanto al LSTM tradicional como a los enfoques de LR.

5.2.2. Evaluación exhaustiva de la precisión del modelo

En este estudio, el modelo ALSTM final, entrenado utilizando datos reducidos mediante PCA (el conjunto de datos de PCA se dividió en conjuntos independientes de entrenamiento, validación y prueba en una proporción de 7:2:1 según el orden temporal), se sometió a una evaluación exhaustiva basada en métricas

[ERROR DE TRADUCCIÓN: Rate limit o cuota DeepL excedida: Quota for this billing period has been exceeded, message: Quota exceeded]

C ALSTMvs. LR 0.005237726 0.000113348 0.010362104 0.046070699*

*Indicates statistical significance at the $\alpha=0.05$ level. In comparison to the LSTM model (Table 7), the ALSTM model demonstrates statistically significant improvements in accuracy, precision, F1 score, and the area under the precision-recall curve (PR-AUC). Furthermore, when compared to LR, ALSTM shows significant enhancements in accuracy, recall, F1 score, and PR-AUC. These findings confirm the superior performance of the ALSTM model relative to both traditional LSTM and LR approaches.

5.2.2. Comprehensive Model Accuracy Assessment

In this study, the final ALSTM model, trained utilizing PCA-reduced data (The PCA dataset was divided into independent training, validation, and test sets in a 7:2:1 ratio according to temporal order), underwent a comprehensive evaluation based on metrics

Forests 2025, 16, 1546 22 of 30 such as precision, recall, F1 score, and PR-AUC value (Figure 11). A detailed explanation of each metric is outlined in Table S2 of the Supplementary Materials. (a) (b) (c) (d) Figure 11. Evaluation metrics curve for PCA data training model. (a) Precision vs. Threshold; (b) Recall vs. Threshold; (c) F1-Score vs. Threshold; (d) Precision-Recall Curve. In Figure 11a, the precision increases rapidly as classification thresholds rise, stabilizing near 1.0 once the threshold exceeds 0.1. This finding indicates that the model achieves

exceptionally high predictive accuracy for the “fire” category over a wider range of thresholds, with the probability of false alarms effectively minimized. In Figure 11b, recall gradually decreases with increasing thresholds but consistently remains above 0.8 within the interval [0, 0.8]. This result statistically confirms the model’s capacity to capture the vast majority of true fire instances, thereby indicating a low risk of false negatives. The F1 score analysis in Figure 11c shows a maximum value of 0.937 at a threshold of approximately 0.02, maintaining a high level close to 0.9 across the broad threshold range [0.02, 0.8]. These findings collectively validate the model’s ability to balance the critical objectives of reducing both false positives and false negatives. Furthermore, PR-AUC in Figure 11d attains a value of 0.987. This result rigorously demonstrates the model’s robustness in handling class imbalance scenarios, indicating that even when confronted with the typical data distribution characteristic of forest fire prediction tasks—where fire instances represent the minority class—the model sustains exceptionally high precision across various recall levels, thereby delivering outstanding overall classification performance. The experimental outcomes consistently and convincingly demonstrate that the forest fire prediction model developed in this study, based on the “spatio-temporal double decoupling” framework, achieves efficient convergence, high stability, exceptional accuracy, and substantial robustness. It effectively addresses the critical issues of feature confusion and insufficient prediction accuracy inherent in traditional methods, providing a dependable technology for accurate early warning of forest fires.

5.3. Verification of Simulation Results

In this study, the parametric simulation experiments were redesigned to evaluate the effect of the meteorological factors (wind speed, humidity, temperature) and combustible

Forests 2025, 16, 1546 23 of 30

factors (FFMC, DMC, DC), within a mountain fire scenario evolution model maintaining consistent initial environmental parameters. By controlling each variable independently, a thorough analysis was conducted to discern the physical effects of these factors on critical fire behavior characteristics, including ignition, spread, and intensity within a three-dimensional, real-terrain environment. This study aimed to validate the plausibility of key factors identified through decoupling analysis in affecting fire evolution, and to evaluate the predictive accuracy of forest fire occurrence probabilities generated by the ALSTM network. Within the context of the designated study area, this study established five temperature gradients for simulation purposes. Each temperature condition was subjected to 30 replicate simulation trials. All subsequent experiments involving additional factors similarly consisted of 30 replicate simulations; this detail will not be reiterated in the following descriptions (Figure 12a–d). The analysis demonstrated that within a single timestep, the likelihood of open fire initiation increased significantly with rising ambient temperatures, and the number of fire points escalated significantly. Furthermore, the proportion of areas affected by open fire exhibited a nonlinear escalation with temperature increases. Figure 12. Effect of forest fire transformation in the test area under different meteorological factors. (a–d) Temperature: (a) A single flame appears at 20°C, (b) three flames appear at 30°C, (c) multiple flames appear at 40°C, (d) combustion occurs at 20°C, 25°C, 30°C, 35°C, and 40°C; (e–h) RH: (e) At 45%, there is a large-scale open flame; (f) At 65%, there is a large-scale open flame; (g) At 85%, there is no combustion; (h) combustion occurs at 45%, 55%, 65%, 75%, and 85%; (i–l) Wind speed: (i) At 2 m/s, one fire point appears; (j) At 4 m/s, open flames appear in the downwind area; (k) At 6 m/s, large-scale open flames appear in the downwind area; (l) combustion occurs at 2 m/s, 3 m/s, 4 m/s, 5 m/s, and 6 m/s.

Forests 2025, 16, 1546 24 of 30

Air humidity (Figure 12e–h) plays a crucial role in determining the ignition threshold and the capacity to sustain flames by regulating the moisture content of. During the simulation experiments, setting the RH to 85% effectively suppressed the generation of open flames throughout the simulation period. This observation elucidates the physical

mechanism whereby combustibles in highly humid environments possess elevated water content, necessitating greater energy expenditure for water evaporation. Additionally, even when ignition occurs at a RH of 65%, both the average spread rate and the burned area remain significantly lower than those observed under low-humidity conditions. Ambient wind affects the trajectory of airborne embers and enhances the evaporation and desiccation of soil and surface fuels at the initial stage of a fire, directly impacting the likelihood and intensity of forest fire spread. The impact of wind speed on the combustion dynamics of forest fires is illustrated in Figure 12i–l. The findings indicate that within a specified range, an increase in wind speed accelerates the initiation of open fires and elevates the number of fire points across individual time intervals. High wind speeds cause flames to become noticeably sloped and elongated, with the fire's head advancing much faster than its flanks and tail, and the dominant fire direction being rapidly propelled along the wind. The model demonstrates the nonlinearity of the wind speed effect (limited at low speeds, dramatic at high speeds) and its dependency on the scenario (notably significant in downwind areas). Additionally, the indirect facilitation of wind speed on the FPMC (via drying) and the ISI (directly affecting spread) were also visualized through the digital twin model. The FPMC serves as a pivotal indicator that characterizes the moisture condition of fine combustibles (e.g., dead leaves, fine twigs) with a diameter of ≤ 1 mm. In Figure 13a–d, the FPMC regulates the ignition temperature and the resistance to flame propagation within the fuel bed. Experimental observations have shown that at low FPMC values, no fire ignition occurs and the fire risk remains minimal. Conversely, at high FPMC values, the rate of flame propagation is significantly rapid, leading to the formation of high-intensity, extensive, and continuous fire lines within a discrete time step. The DMC quantifies the moisture content of medium-grained surface combustible materials and plays a critical role in moderating fire intensity. Elevated DMC values indicate a deeper drying of these combustibles. Experimental results in Figure 13e–h demonstrate that high DMC values substantially extend the duration of flame maintenance, thereby increasing the total energy released from individual fires and contributing more significantly to subsurface or deep-seated fires. The DC evaluates the long-term drought severity affecting deep organic soils. It reflects the cumulative impact of seasonal precipitation deficit on combustible materials and their correlation with prolonged flaming and expansion. An elevated DC indicates an extremely dry state of deep combustibles following prolonged drought conditions. Simulation results in Figure 13i–l indicate that as the DC value increases within a certain range, the depth of combustible material burning and the size of the overfire area per unit time step also increase. The digital twin simulation result effectively reproduces and validates the core findings derived from the independent analysis, providing an intuitive visual representation of the physical and spatial processes impacting these factors and quantifying the dynamic mechanisms of traditional FWI system metrics over time. Additionally, a multitude of simulated scenarios encompassing various meteorological and combustible conditions have been established. The final combustion states in these scenarios align closely with the probabilities of high and low fire occurrences as predicted by the ALSTM model, based on identical input parameters. This congruence at the level of three-dimensional physical mechanisms substantiates the ALSTM prediction model significantly beyond

DMC=10; (g) Large-scale open flames appear when DMC=40; (h) Combustion states at DMC values of 1, 5, 10, 20, and 40; (i) No combustion occurs when DC=10; (j) Small-scale open flames appear when DC=80; (k) Large-scale open flames appear when DC=200; (l) Combustion states at DC values of 10, 20, 80, 100, and 200.

Conclusions

[ERROR DE TRADUCCIÓN: Rate limit o cuota DeepL excedida: Quota for this billing period has been exceeded, message: Quota exceeded]

To address three core challenges in forest fire research—feature confusion, insufficient prediction accuracy, and the absence of situational models, this study introduces the novel “decoupling analysis-model prediction-scenario validation” trinity framework, developed to analyze meteorological and combustible state indicators in Algeria using PCA-SHAP synergistic analysis. The dryness of combustible materials, accounting for 52.61% of the variance in PC1, serves as the primary driving factor. Additionally, W_s emerged as a critical factor for rapid fire propagation and increased fire intensity, where e as humidity was identified as the central negative driving factor. The forest fire prediction model, based on the “spatial-temporal double decoupling” mechanism. The model achieved mean values of 97.82% accuracy (± 0.0213), 94.61% recall (± 0.0373), and a PR-AUC of 99.45% (± 0.0048), significantly outperforming traditional methods. These results confirm that the proposed model exhibits efficient convergence, high stability, and robustness, significantly addressing the issues of feature confusion and insufficient prediction accuracy inherent in traditional methods. This model also pioneers a verification paradigm, driven by digital twins and

Forests 2025, 16, 1546 26 of 30
 based on a physics engine, to achieve closed-loop verification of ALSTM prediction results and three-dimensional fire evolution. This approach provides a dynamic and traceable physical mechanism verification environment for complex prediction models. This study adopts Algerian forests as a representative case, offering practical guidance for forest fire early warning systems and resource allocation strategies: Monitoring and forecasting efforts should prioritize combustible moisture conditions, particularly under conditions of high temperatures and low humidity, necessitating heightened vigilance. FFMCI, ISI, RH, and temperature are identified as key indicators for primary monitoring in forest fire risk assessment. The findings underscore the practical value of digital twin technology in enhancing training and simulation exercises. Accordingly, relevant agencies are encouraged to develop an analogous simulation-based prediction system to support the training of fire commanders and facilitate decision-making drills across diverse disaster scenarios, thereby strengthening emergency preparedness and response capabilities. The study acknowledges certain limitations due to data dimensions and computational constraints: (1) The model training depends on data from specific climatic zones in Algeria, exhibiting strong regional specificity. Its generalizability to broader forested areas remains to be verified. (2) The physical-spatial processes under the coupled interaction of the influencing factors are highly complex. The study constructs a mountain fire scenario evolution model based on a simplified hypothetical dynamics module, which restricts the precision of quantitative fire behavior simulations and limits the capacity to fully capture the impacts of extreme weather events. Future research will aim to incorporate multi-region data (e.g., historical fire and environmental records from tropical rainforest regions beyond the Mediterranean) to construct a cross-regional generalized model, enhancing the universality of the framework. It will also

explore the integration of cutting-edge deep learning models, such as ISONet [85], within the framework established in this study to optimize the prediction module. Furthermore, introducing the physical driving equations of extreme weather will improve the accuracy of physical simulations. Supplementary Materials: The following supporting information can be downloaded at <https://www.mdpi.com/article/10.3390/f16101546/s1>: Table S1. Differences and Connections Between the Tripartite Framework and Existing Paradigms; Figure S1: Interaction diagram of forest land digital twins; Table S2. Model performance evaluation index.

Author Contributions: Conceptualization, W.L.; data curation, W.L.; formal analysis, W.L.; funding acquisition, W.Z. and Y.T.; investigation, W.L.; methodology, W.L. and W.F.; project administration, W.Z.; resources, W.L.; software, W.L. and W.F.; supervision, W.Z. and Y.T.; validation, W.L. and W.F.; visualization, W.L.; writing—original draft, W.L.; writing—review and editing, W.L. All authors have read and agreed to the published version of the manuscript.

Funding: This research was funded by the Innovation and Entrepreneurship Training Program for Undergraduates of Sichuan Normal University under grant number 202410636159; the Open Project of Key Laboratory in Sichuan Provincial Universities (Technology of Public Fire Prevention and Control) under grant number SCKLPFPCT2024Y09; and the Sichuan Science and Technology Program under grant number 2024YFFK0111.

Data Availability Statement: The data will be made available on request.

Conflicts of Interest: The authors declare no conflict of interest.

Forests 2025, 16, 1546 27 of 30

References

[ERROR DE TRADUCCIÓN: Rate limit o cuota DeepL excedida: Quota for this billing period has been exceeded, message: Quota exceeded]

1. Bargali, H.; Pandey, A.; Bhatt, D.; Sundriyal, R.C.; Uniyal, V.P. Forest fire management, funding dynamics, and research in the burning frontier: A comprehensive review. *Trees For People* 2024, 16, 100526. [CrossRef]
2. San-Miguel-Ayanz, J.; Durrant, T.; Boca, R.; Libertà, G.; Branco, A.; de Rigo, D.; Ferrari, D.; Maianti, P.; Artés Vivancos, T.; Costa, H.; et al. Advance EFFIS Report on Forest Fires in Europe, Middle East and North Africa 2017; European Commission: Luxembourg, Luxembourg, 2020; pp. 31–32. ISBN 978-92-79-92776-8. [CrossRef]
3. Abid, F.; Izeboudjen, N. Predicting Forest Fire in Algeria Using Data Mining Techniques: Case Study of the Decision Tree Algorithm. In *Proceedings of the Advanced Intelligent Systems for Sustainable Development (AI2SD'2019)*, Marrakech, Morocco, 8–11 July 2019; pp. 363–370. [CrossRef]
4. Mishra, M.; Guria, R.; Baraj, B.; Nanda, A.P.; Santos, C.A.G.; da Silva, R.M.; Laksono, F.X.A.T. Spatial analysis and machine learning prediction of forest fires susceptibility: A comprehensive approach for effective management and mitigation. *Sci. Total Environ.* 2024, 926, 171713. [CrossRef] [PubMed]
5. Abatzoglou, J.T.; Kolden, C.A.; Cullen, A.C.; Sadegh, M.; Williams, E.L.; Turco, M.; Jones, M.W. Climate change has increased the odds of extreme regional forest fire years globally. *Nat. Commun.* 2025, 16, 6390. [CrossRef]
6. El Garroussi, S.; Di Giuseppe, F.; Barnard, C.; Wetterhall, F. Europe faces up to tenfold increase in extreme fire in a warming climate. *npj Clim. Atmos. Sci.* 2024, 7, 30. [CrossRef]
7. Turco, M.; Llasat, M.C.; von Hardenberg, J.; Provenzale, A. Impact of climate variability on summer fires in a Mediterranean environment (northeastern Iberian Peninsula). *Clim. Change* 2013, 116, 665–678. [CrossRef]
8. Zumbinnen, T.; Pezzatti, G.B.; Menéndez, P.; Bugmann, H.; Bürgi, M.; Conedera, M. Weather and human impact on forest fires: 100 years of fire history in two climatic regions of Switzerland. *For. Ecol. Man*

ag.2011,261,2188–2199.[CrossRef] 9. Mollicone,D.;Eva,H.D.;Achard,F.HumanroleinRussian wildfires.Nature2006,440,436–437.[CrossRef] 10. Naderpour, M.; Rizeei, H.M.; Ramezani, F. Forest fire risk prediction: A spatial deep neural network-based framework. RemoteSens.2021,13,2513.[CrossRef] 11. Wu,Z.;Li,M.;Wang,B.;Quan,Y.;Liu,J.Usingartificialintelligence to estimate the probability of forest fires in Heilongjiang, northeast China. RemoteSens.2021,13,1813.[CrossRef] 12. AlgerianForestFires—UCIMachine LearningRepository.Availableonline:<https://archive.ics.uci.edu/dataset/547/algerian+forest+fires+dataset>(accessedon24October2024). 13. Moritz, M.A.; Batllori, E.; Bradstock, R.A.; Gill, A.M.; Handmer, J.; Hessburg, P.F.; Leonard, J.; McCaffrey, S.; Odion, D.C.; Schoennagel, T.; et al. Learning to coexist with wildfire. Nature2014,515,58–66.[CrossRef] 14. Black, F.; Schulze, P.; Unger, B. Efficient Wildland Fire Simulation via Nonlinear Model Order Reduction. Fluids2021,6,280. [CrossRef] 15. Abram, N.J.; Henley, B.J.; SenGupta, A.; Lippmann, T.J.R.; Clarke, H.; Dowdy, A.J.; Sharples, J.J.; Nolan, R.H.; Zhang, T.; Wooster, M.J.; et al. Connections of climate change and variability to large and extreme forest fires in southeast Australia. Commun. Earth Environ.2021,2,8.[CrossRef] 16. Jolliffe, I.T.; Cadima, J. Principal component analysis: A review and recent developments. Philos. Trans. R. Soc. A Math. Phys. Eng. Sci.2016,374,20150202.[CrossRef] 17. Ermitão, T.; Páscoa, P.; Trigo, I.; Alonso, C.; Gouveia, C. Mapping the Most Susceptible Regions to Fire in Portugal. Fire2023,6, 254.[CrossRef] 18. Wang, Q.; Hao, Y. ALSTM: An attention-based long short-term memory framework for knowledge-based reasoning. Neurocomputing 2020,399,342–351.[CrossRef] 19. Wang, Y.; Li, H.; Huang, J.; Su, C.; Yang, B.; Qi, C. An improved bar-shaped sliding window CNN tailored to industrial process historical data with applications in chemical operational optimizations. Ind. Eng. Chem. Res.2019,58,21219–21232.[CrossRef] 20. Zhang, L.; Wang, L.; Ji, D.; Xia, Z.; Nan, P.; Zhang, J.; Li, K.; Qi, B.; Du, R.; Sun, Y.; et al. Explainable ensemble machine learning revealing the effect of meteorology and sources on ozone formation in megacity Hangzhou, China. Sci. Total Environ.2024,922, 171295.[CrossRef][PubMed] 21. Iban, M.C.; Sekertekin, A. Machine learning based wildfire susceptibility mapping using remotely sensed fire data and GIS: A case study of Adana and Mersin provinces, Turkey. Ecol. Inform.2022,69,101647.[CrossRef] 22. García, M.V.; Aznarte, J.L. Shapley additive explanations for NO forecasting. Ecol. Inform.2020,56,101039.[CrossRef] 23. Yue, W.; Ren, C.; Liang, Y.; Liang, J.; Lin, X.; Yin, A.; Wei, Z. Assessment of wildfire susceptibility and wildfire threats to ecological environment and urban development based on GIS and multi-sourced data: A case study of Guilin, China. Remote Sens.2023,15, 2659.[CrossRef] 24. Encinas, L.H.; White, S.H.; Del Rey, A.M.; Sánchez, G.R. Modelling forest fire spread using hexagonal cellular automata. Appl. Math. Model.2007,31,1213–1227.[CrossRef] 25. Koo, E.; Pagni, P.; Woycheese, J.; Stephens, S.; Weise, D.; Huff, J. A simple physical model for forest fire spread rate. Fire Saf. Sci. 2005,8,851–862.[CrossRef]

Forests2025,16,1546 28 of 30 26. Yassemi, S.; Dragićević, S.; Schmidt, M. Design and implementation of an integrated GIS-based cellular automata model to characterize forest fire behaviour. Ecol. Model.2008,210,71–84.[CrossRef] 27. Sun, L.; Xu, C.; He, Y.; Zhao, Y.; Xu, Y.; Rui, X.; Xu, H. Adaptive forest fire spread simulation algorithm based on cellular automata. Forests2021,12,1431.[CrossRef] 28. Li, L.; Sali, A.; Noordin, N.K.; Ismail, A.; Hashim, F. Prediction of peatland forest fires in Malaysia using machine learning. Forests2023,14,1472.[CrossRef] 29. Meng, Q.; Lu, H.; Huai, Y.; Xu, H.; Yang, S. Forest fire spread simulation and fire extinguishing visualization research. Forests 2023,14,1371.[CrossRef] 30. Farguella, A.; Cortés, A.; Margalef, T.; Miró, J.R.; Mercader, J. Scalability of a multi-physics system for forest fire spread prediction in multi-core platforms. J. Supercomput.2019,75,1163–1174.[CrossRef] 31. Sun, X.; Li, N.; Chen, D.; Chen, G.; Sun, C.; Shi, M.; Gao, X.; Wang, K.; Hezam, I.M. A Forest Fire Prediction Model Based on Cellular Automata and Machine Learning. IEEE Access2024,12,55389–55403.[CrossRef] 32. Li, X.; Zhang, M.; Zhang, S.; Liu, J.; Sun, S.; Hu, T.; Sun, L. Simulating Forest Fire Spread with Cellular Automata Driven by a LSTM Based Speed Model. Fire2022,5,13.[CrossRef] 33. Xu, Y.; Li, D.; Ma, H.; Li

n, R.; Zhang, F. Modeling Forest Fire Spread Using Machine Learning-Based Cellular Automata in a GIS Environment. *Forests* 2022, 13, 1974. [CrossRef] 34. Teng, L.; Ji, Y.; Zhaorong, O.; Qiang, Y.; Yong, L.; Qiu, W. Comprehensive assessment and spatial pattern study on forest fire risk in Yunnan Province. *China Saf. Sci. J.* 2021, 31, 167. [CrossRef] 35. Wei, S.; Luo, S.; Luo, B.; Li, X.; Wang, Z.; Wu, Z.; Zhou, Y.; Zhong, Y.; Li, Q. Occurrence regularity of forest fire under the background of climate change. *For. Environ. Sci.* 2020, 36, 133–143. 36. Tian, C.; Su, Z.; Yang, X.; Guo, F. Investigations on spatial distribution and driving factors of forest fire in western Fujian. *For. Environ.* 2017, 37, 88–94. 37. Xiao, Y.; Ji, P. Predicting forest fire occurrence based on zero-inflated negative binomial model using Bayesian method. *J. Cent. South Univ. For. Technol.* 2021, 41, 49–56. [CrossRef] 38. Gao, B.; Chen, X.; Shan, Z.H.; Han, X.Y.; Shan, Y.L.; Yin, S.N.; Yu, B. Prediction of forest fire probability in Daxing'an Mountains area based on Logistic regression model. *J. Saf. Sci. Technol.* 2022, 18, 163–168. 39. Preisler, H.K.; Westerling, A.L. Statistical Model for Forecasting Monthly Large Wildfire Events in Western United States. *J. Appl. Meteorol. Climatol.* 2007, 46, 1020–1030. [CrossRef] 40. Wang, Y.; Zhao, L.; Yang, X.; Liang, L.; Yuan, X.; Ren, L.; Zhang, H. Study on the Impact of Atmospheric and Topographical Environment on Wildfire Spread: A Case Study of a Forest Fire in Shanxi Province. *Disaster Sci.* 2023, 38, 118–125. 41. Singh, K.R.; Neethu, K.; Madhurekha, K.; Harita, A.; Mohan, P. Parallel SVM model for forest fire prediction. *Soft Comput. Lett.* 2021, 3, 100014. [CrossRef] 42. Majid, S.; Alenezi, F.; Masood, S.; Ahmad, M.; Gündüz, E.S.; Polat, K. Attention based CNN model for fire detection and localization in real-world images. *Expert Syst. Appl.* 2022, 189, 116114. [CrossRef] 43. Ding, Y.; Zhu, Y.; Feng, J.; Zhang, P.; Cheng, Z. Interpretable spatio-temporal attention LSTM model for flood forecasting. *Neurocomputing* 2020, 403, 348–359. [CrossRef] 44. Yu, Y.; Kim, Y.-J. Attention-LSTM-attention model for speech emotion recognition and analysis of IEMOCAP database. *Electronics* 2020, 9, 713. [CrossRef] 45. Lin, X.; Li, Z.; Chen, W.; Sun, X.; Gao, D. Forest fire prediction based on long-and short-term time-series network. *Forests* 2023, 14, 778. [CrossRef] 46. Zhu, J.; Liu, X.; Cheng, P.; Wang, M.; Huang, Y. Unveiling spatiotemporal patterns of wildfire risk: A transformer-based earth system analysis. *Clim. Dyn.* 2025, 63, 21. [CrossRef] 47. Hancock, J.T.; Khoshgoftar, T.M.; Liang, Q. A problem-agnostic approach to feature selection and analysis using shap. *J. Big Data* 2025, 12, 12. [CrossRef] 48. Abdollahi, A.; Pradhan, B. Explainable artificial intelligence (XAI) for interpreting the contributing factors feed into the wildfire susceptibility prediction model. *Sci. Total Environ.* 2023, 879, 163004. [CrossRef] 49. Sanchez-Guzman, G.; Velasquez, W.; Alvarez-Alvarado, M.S. Modeling a simulated forest to get burning times of tree species using a digital twin. In *Proceedings of the 2022 IEEE 12th Annual Computing and Communication Workshop and Conference (CCWC)*, Las Vegas, NV, USA, 26–29 January 2022; pp. 639–643. 50. Huang, Y.; Li, J.; Zheng, H. Modeling of Wildfire Digital Twin: Research Progress in Detection, Simulation, and Prediction Techniques. *Fire* 2024, 7, 412. [CrossRef] 51. Zhong, C.; Cheng, S.; Kasoar, M.; Arcucci, R. Reduced-order digital twin and latent data assimilation for global wildfire prediction. *Nat. Hazards Earth Syst. Sci.* 2023, 23, 1755–1768. [CrossRef]

Forests 2025, 16, 1546 29 of 30 52. Dourvas, N.I.; Papagianni, A.; Koulalis, I.; Ioannidis, K.; Vrochidis, S.; Kompatsiaris, I. A nearly-warning system for fires spreading by monitoring simple climate conditions and combining Cellular Automata with Digital Twins. In *Proceedings of the 2022 IEEE International Workshop on Metrology for Living Environment (Metro LivEn)*, Cosenza, Italy, 25–27 May 2022; pp. 252–257. [CrossRef] 53. Ghodrati, M.; Shakeriaski, F.; Fanaee, S.A.; Simeoni, A. Software-Based Simulation of Wildfire Spread and Wind-Fire Interaction. *Fire* 2023, 6, 12. [CrossRef] 54. Eghdami, M.; Juliano, T.W.; Jiménez, P.A.; Kosovic, B.; Castellnou, M.; Kumar, R.; Vila-Guerau de Arellano, J. Characterizing the Role of Moisture and Smoke on the 2021 Santa Coloma de Queralt Pyroconvective Event Using WRF-Fire. *J. Adv. Model. Earth Syst.* 2023, 15, e2022MS003288. [CrossRef] 55. Huang, J.; Lucash, M.S.; Scheller, R.M.; Klippel, A. Walking through the forests of the future: Using data-driven virtual reality to visualize forests under climate change. *Int. J. Geogr. Inf. Sci.* 2021, 35, 1155–1178. [CrossRef] 56. Zheng, H.; Wang, J.; Wang, S.; Gu, W. Educational application of cognitive digital twins: Connotation, Dil

emmaandcountermeasures.Mod.DistanceEduc.2021,01,13–23.[CrossRef] 57. Tao,F.;Xiao,B.;Qi,Q.;Cheng,J.;Ji,P.Digitaltwinmodeling.J.Manuf.Syst.2022,64,372–389.[CrossRef] 58. Tao,F.;Qi,Q.Makemoredigitaltwins.Nature2019,573,490–491.[CrossRef] 59. Li,H.;Tao,F.;Wang,H.;Song,W.;Zhang,Z.;Fan,B.B.;Wu,C.;Li,Y.;Li,L.L.;Wen,X.Y.;etal.IntegrationFrameworkand Key TechnologiesofComplexProductDesign-ManufacturingBasedonDigitalTwin.Comput.Integr .Manuf.Syst.2019,25,1320–1336. 60. Cimino, C.; Negri, E.; Fumagalli, L.Reviewofdigitaltwinapplicationsinmanufacturing. Comput. Ind. 2019, 113, 103130. [CrossRef] 61. Yeh,A.G.Fromurbanmodelling,GIS,thedigital,intelligent,andthesmartcitytothedigitaltwin citywithAI.Environ.Plan.B UrbanAnal.CitySci.2024,51,1085–1088.[CrossRef] 62. Ferr é-Bigorra,J.;Casals,M.;Gangoilels,M.Theadoptionofurbandigitaltwins.Cities2022,131,103905.[CrossRef] 63. Elayan,H.;Aloqaily,M.;Guizani,M.Digitaltwinforintelligentcontext-awareIoTthehealth caresystems.IEEEInternetThingsJ. 2021,8,16749–16757.[CrossRef] 64. Liu,Y.;Zhang,L.;Yang ,Y.;Zhou,L.;Ren,L.;Wang,F.;Liu,R.;Pang,Z.;Deen,M.J.Anovelcloud-basedframeworkforthe elderlyhealthcareservicesusingdigitaltwin.IEEEAccess2019,7,49088–49101.[CrossRef] 65. Sun,T.;He,X.;Song,X.;Shu,L.;Li,Z.Thedigitaltwininmedicine:Akeytothefutureofhealthcare?Front. Med.2022,9,907066. [CrossRef] 66. Aydemir,H.;Zengin,U.;Durak,U.Thedigitaltwinparadigmfor aircraftreviewandoutlook.InProceedingsoftheAIAAScitech 2020Forum,Orlando,FL,USA,6–10January2020;p.553.[CrossRef] 67. Kairat,K.;Ildar,P.;Karyg ash,A.;Saule,B.;Indira,K.;Markhaba,K.;Aizhan,B.DigitalTwinsTechnologyintheEducational ProcessoftheAviationEquipmentRepair.Indones.J.Electr.Eng.Comput.Sci2023,32,752–762.[CrossRef] 68. Qiu, H.; Zhang, H.; Lei, K.; Zhang, H.; Hu, X. Forest digital twin: A new tool for forest management practices based on Spatio-TemporalData,3DsimulationEngine,andintelligentinter activeenvironment.Comput.Electron.Agric.2023,215,108416. [CrossRef] 69. Cirulis,A.;Taube, L.;Erica,Z.Automatedgenerationofdigitaltwininvirtualrealityforinteractionwithspecificnatureecos ystem. InProceedingsoftheInternationalConferenceonHuman-ComputerInteraction,Virtual,26June–1July2022;pp. 187–202. [CrossRef] 70. TheCanadianForestFireWeatherIndex(FWI)System.Availableonline:<https://cwffis.cfs.nrcan.gc.ca/background/summary/fwi>(accessedon23April2025). 71. Xin,X.-Y.;Jiang,H.;Zhou,G.-M.;Yu,S.-Q.;Wang,Y.-H.TheprincipleandapplicationoftheCanadianForestFireHazardClimate Index(FWI)system.J.ZhejiangAgric.For.Univ.2011,28,314–318. 72. Abdi,H.;Williams,L.J.Principalcomponentanalysis.WileyInterdiscip.Rev.Comput.Stat.2010,2,433–459.[CrossRef] 73. Souane,A.A.; Khurram,A.; Huang,H.; Shu,Z.; Feng,S.; Belgherbi,B.; Wu,Z.UtilizingMachineLearningandGeospatial TechniquetoEvaluatePost-FireVegetationRecoveryinMediterraneanForestEcosystem:Tenira,Algeria.Forests2025,16,53. [CrossRef] 74. Lundberg,S.M.;Lee,S.-I.Aunifiedapproachtointerpretingmodelpredictions.Adv.NeuralInf.Process.Syst.2017,30,4768–4777. 75. Molnar, C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, 3rd ed.; 2025. Available online: <https://christophm.github.io/interpretable-ml-book>(accessedon24May2025). 76. Heidari,A.;Khovalyg,D.Short-termenergyusepredictionofsolar-assistedwaterheatingssystem:Applicationcase ofcombined attention-basedLSTMandtime-seriesdecomposition.Sol.Energy2020,207,626–639.[CrossRef] 77. Huang,J.Q.;Qin,L.X.Studyonthecorrelationpredictionoftemperatureandrainfallusingalstm model.J.GuangxiUniv.(Nat. Sci.Ed.)2021,46,1024–1035.[CrossRef] 78. Wenfeng, S. In-Depth Understanding of Natural Language Processing: From Deep Learning to Large Model Applications, 1st ed.; TsinghuaUniversityPress:Beijing,China,2025.

[ERROR DE TRADUCCIÓN: Rate limit o cuota DeepL excedida: Quota for this billing period has been exceeded, message: Quota exceeded]

terpretingmodelpredictions.Adv.NeuralInf.Process.Syst.2017,30,4768–4777. 75. Molnar, C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable, 3rd ed.; 2025. Available online: <https://christophm.github.io/interpretable-ml-book>(accessedon24May2025). 76. Heidari,A.;Kh

ovaly, D. Short-term energy use prediction of solar-assisted water heating system: Application case of combined attention-based LSTM and time-series decomposition. *Sol. Energy* 2020, 207, 626–639. [CrossRef]

77. Huang, J.Q.; Qin, L.X. Study on the correlation prediction of temperature and rainfall using a LSTM model. *J. Guangxi Univ. (Nat. Sci. Ed.)* 2021, 46, 1024–1035. [CrossRef]

78. Wenfeng, S. *In-Depth Understanding of Natural Language Processing: From Deep Learning to Large Model Applications*, 1st ed.; Tsinghua University Press: Beijing, China, 2025.

Forests 2025, 16, 1546–30 of 30

79. Zohdi, T. A machine-learning framework for rapid adaptive digital-twin based fire-propagation simulation in complex environments. *Comput. Methods Appl. Mech. Eng.* 2020, 363, 112907. [CrossRef]

80. Wu, Z.; Wang, B.; Li, M.; Tian, Y.; Quan, Y.; Liu, J. Simulation of forest fire spread based on artificial intelligence. *Ecol. Indic.* 2022, 136, 108653. [CrossRef]

81. Rui, X.; Hui, S.; Yu, X.; Zhang, G.; Wu, B. Forest fire spread simulation algorithm based on cellular automata. *Nat. Hazards* 2018, 91, 309–319. [CrossRef]

82. Wang, Z. Current forest fire danger rating system. *J. Nat. Disasters* 1992, 1, 39–44. [CrossRef]

83. Zhang, X.; Liu, P. Research on improvement of Wang Zhengfei's forest fire spread model. *J. Shandong For. Sci. Technol.* 2020, 50, 1–6.

84. Gabriel, K.R. The biplot graphic display of matrices with application to principal component analysis. *Biometrika* 1971, 58, 453–467. [CrossRef]

85. Xiang, Q.; Wang, X.; Song, Y.; Lei, L. ISONet: Reforming 1D CNN for an aero-engine system inter-shaft bearing fault diagnosis via input spatial over-parameterization. *Expert Syst. Appl.* 2025, 277, 127248. [CrossRef]

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.